

周猛

FAE 工程师 | AI 算力硬件与大模型适配

电话: 17609439323 邮箱: 1428614426@qq.com 性别: 男 年龄: 32 现所在地: 北京

求职意向

意向岗位: FAE 意向城市: 北京 期望薪资: 35-45K 求职类型: 社招

核心优势

- AI 算力全栈技术闭环: 精通 GPU 服务器 / 加速卡 POC 验证、主流大模型适配、集群部署与故障闭环, 覆盖从选型到量产的完整技术链路。
- 多行业头部客户实战沉淀: 主导互联网、央国企、金融、工业机器人等多场景标杆项目, 具备成熟的国产化信创与 AI 平台落地经验, 能快速匹配不同行业业务需求。
- 售前到量产的全流程交付能力: 兼具方案设计、现场攻坚、跨部门协同与批量交付管理能力, 可独立推进项目从需求对接、POC 验证到订单落地的全流程闭环。
- 标准化与长期价值沉淀: 擅长将项目经验转化为可复用的适配流程、测试规范与上线标准, 为客户规模化部署提供稳定支撑, 保障业务长期可靠运行。

工作经历

2021.11 - 至今

摩尔线程智能科技(北京)股份有限公司 | FAE | AI算力硬件与大模型适配

负责 AI GPU 产品全生命周期技术服务, 覆盖大客户 POC 支持、OEM 适配、服务器交付、故障闭环全流程, 协调内部资源解决客户技术诉求, 保障项目落地与客户满意度。

大客户技术支持与 POC 落地

- 聚焦互联网、央国企等头部客户 AI GPU 服务器场景, 提供 GPU 整机基础测试、模型训推全流程技术支撑, 负责 AI 模型测试方案制定与执行, 协助客户完成模型适配、性能调优。
- 全程支撑 POC 测试, 从测试环境搭建、用例设计、执行验证到结果复盘, 累计支持 5+ 个 POC 项目, 助力客户技术选型决策效率和项目落地效率。

OEM 厂商适配与量产推进

- 负责国内头部 OEM 客户的 GPU 适配导入工作, 推进 GPU 板卡的兼容性验证、集成调试, 解决适配过程中的软硬件技术瓶颈。
- 累计推动 3 家头部 OEM 客户产品顺利量产, 支撑 10+ 个 OEM 大型项目落地。

批量交付与故障闭环管理

- 主导大客户 GPU 服务器交付工作, 覆盖机房从 0 搭建、硬件开箱验货、组装调试、系统安装 (麒麟、Ubuntu 等)、GPU 驱动部署、集群 RoCE 组网及基础测试全流程, 完成交付验收。
- 负责 GPU RMA 流程全管控, 接收客户故障反馈, 协调内部资源完成故障 GPU 的检测、分析与定位, 制定解决方案并推动落地。

跨部门协同与项目推进

- 担任跨部门沟通桥梁, 精准传递客户需求, 协调研发、测试、生产等内部团队, 推动客户问题与需求高效落地。
- 作为全功能 FAE 独立负责售前技术支持、售后管理维护及项目全流程推进。

国内主流开源模型适配调优

- 主流888国产开源模型部署测试与适配调优: DeepSeek、GLM、Kimi、Qwen、MiniMax、Wan、Hunyuan 等大语言/多模态模型; 推理框架以 vLLM、SGLang P/D 分离为主

2019.11 - 2021.11

北京同方信息安全股份有限公司 | 测试运维 | 服务器硬件

负责硬件产品全流程测试支持，涵盖测试计划制定、测试执行、故障定位、报告输出全环节，联动多部门保障产品质量与交付进度。

- 根据项目需求制定详细的硬件测试计划，明确测试目的、范围、方法与资源分配。
- 负责执行各类硬件测试，包括功能测试、性能测试、兼容性测试等。
- 对测试过程中出现的故障进行深入分析，定位问题根因并提供有效解决方案，撰写详细测试报告，为产品改进和迭代提供数据支撑。
- 与研发、生产、质量等部门保持密切沟通，优化测试流程，保障产品按期交付。

2017.03 - 2019.11 联想北京信息技术有限公司 | 测试开发 | 计算机硬件

负责服务器全平台一站式测试验证，覆盖硬件、固件、系统、网络、存储及可靠性全维度，保障服务器量产交付与集采项目落地。

硬件与固件测试

- 承担 CPU、内存、存储、背板、机箱结构的功能、性能、压力与兼容性验证，熟练使用各类专业硬件测试工具，累计完成 30+ 款服务器硬件测试。
- 完成 BIOS、BMC 全功能测试与固件调试，精通 IPMI、WebUI 操作及远程部署环境搭建。

整机与可靠性测试

- 开展网卡适配、网络压测、整机高负载稳定性测试及多操作系统兼容性验证，覆盖 Windows、Linux、麒麟等主流系统，保障服务器多场景适配能力。
- 制定环境可靠性测试方案，执行高低温、震动、跌落等测试，全程追踪缺陷闭环。

项目经历

2025.10 - 至今

美团互联网客户 POC 项目 | FAE 技术支持 |

项目背景

美团需对 AI 平台、搜广推业务模型进行硬件适配验证，完成 GPU 服务器选型，保障自研大模型业务落地性能与稳定性。

核心贡献

- 负责服务器组 POC 测试，主导 GPU 服务器样机送测工作，完成 GPU 基准准入测试及训推模型测试支持，涵盖 Llama3 训练及 DeepSeek 671B 双机模型推理等模型测试。
- 主导业务组模型适配工作，支持美团 AI 平台适配搜广推业务模型及自研 Longcat 1.0/2.0模型的适配与优化。
- 参与客户现场部署测试，提供 7x24 小时现场技术支持与问题排查。

项目成果

测试结果满足客户性能预期，GPU 方案成功中标美团年度算力集采项目，客户满意度达 98%。

项目背景

客户为支撑新一代 AI 业务落地，启动 GPU 服务器/加速卡的选型验证与规模化部署前置测试，需在指定周期内完成硬件适配、性能调优、稳定性验证与上线准入标准制定。

项目职责

- 作为项目 FAE 负责人，主导 GPU 板卡/服务器 POC 全流程验证工作，统筹送测准入、整机硬件联调适配各环节落地推进，联动客户算力平台团队，协同推进硬件参数调优、适配流程标准化、现场技术支持等核心工作。

解决方案

- 搭建全场景验证体系，完成基准性能测试、大模型训练/推理场景适配验证，实现主流业务模型的性能与稳定性全维度校验，开展功耗/温控/性能基线多轮调优验证，梳理输出标准化适配流程与上线校验标准。
- 提供 7×24 小时现场技术支持，快速响应测试过程中的问题排查与故障闭环，协助制定硬件上线准入规范与稳定性测试方案，覆盖全部核心业务校验场景。

项目成果

按计划完成全流程验证节点，适配方案性能满足客户业务预期，顺利通过客户选型验收，输出的标准化适配流程与测试规范可复用至后续规模化部署环节。

项目背景

中电科智能院自主可控年度采购 AI 算力集群，涉及 POC 测试、投标、批量交付全流程，需保障集群稳定运行满足 AI 科研需求。

核心贡献

- 负责项目控标项把控，梳理技术优势与落地案例，投标文件评分位列第一，成功中标项目。
- 负责 POC 项目送测、样机对接、GPU 上下架对接，完成 RoCE 网络及环境部署，POC 测试一次性通过客户验收。
- 提供 AI 模型适配支持与技术对接，完成 9 款主流模型（如九格 LoRA 训推、Qwen2.5/3/3.5、DeepSeek-R1、Wan 2.1、GLM-5、Deepseek-V4-Flash/Pro 等）的适配调优，客户现场集群模型部署调试，性能压测、精度测试，模型训推性能满足客户要求。
- 主导批量服务器交付实施，提供技术对接、集群搭建部署一体化完整技术支持。

项目成果

项目正在按计划进行交付中，交付后将为后续央国企算力集群项目合作建立标杆案例。

项目背景

本项目联合世纪互联开展异构部署验证，基于摩尔线程 S5000、B300 硬件，依托 SGLang 框架完成 GLM-5.1 大模型 PD（预填充-解码）分离架构测试。待测试验证通过后，客户计划落地该方案，对外提供算力租赁等业务服务。

项目职责

- 负责摩尔线程 S5000、B300 硬件平台侧技术支持，完成硬件环境、驱动、MUSA-SDK 环境部署与问题排查。
- 指导 SGLang 框架 PD（预填充-解码）分离异构架构部署，协助完成预填充节点、解码节点拆分配置、多节点网络连通、服务调通。

- 定位并解决部署过程中硬件适配、驱动、容器、网络通信、服务端口、PD 路由转发等各类故障。
- 配合完成 GLM-5.1 模型的推理功能验证、性能调优，输出测试过程技术支持，协助客户完成业务可行性验证。
- 同步平台适配约束、最佳实践，为客户后续算力租赁业务上线输出技术建议。

解决方案

- 针对世纪互联算力租赁业务诉求，采用SGLang PD 分离异构部署架构：
- 使用摩尔线程 S5000、B300 异构硬件集群，拆分预填充（Prefill）与解码（Decode）业务链路；
- Prefill 节点负责处理用户输入请求，Decode 节点承接 token 生成输出，通过 Router 完成请求调度转发；
- 依托 MUSA 软件栈完成 GLM-5.1 大模型推理适配，充分发挥异构硬件算力；
- 通过多节点集群化部署，满足算力租赁场景多用户并发推理的业务需求，验证整套方案的可行性、稳定性，支撑业务上线。

项目成果

- 完成 S5000+B300 异构硬件平台下，GLM-5.1 模型基于 SGLang PD-分离架构的部署调通，功能验证正常。
- 解决部署过程中环境依赖、容器、跨节点通信、服务异常等多项适配问题，沉淀异构 PD 部署配置与最佳实践。
- 完成整套方案可行性验证，方案具备落地条件，客户计划基于该架构上线，开展对外算力租赁业务。
- 输出适配指导，为后续业务上线运维、故障处理提供技术依据。

2022.03 - 2022.09

紫光计算机-邮储集采项目 | FAE 技术支持 |

项目背景

本项目为中国邮政储蓄银行年度 IT 设备集采项目，核心目标是推进国有金融机构信创体系落地，完成原有国外品牌图形计算设备的国产化替代，保障银行终端系统的自主可控与数据安全。

项目职责

- 协助项目组开展邮储银行图形工作站设备需求调研，梳理柜面业务、后台建模、虚拟化办公等多场景 GPU 性能要求，输出需求匹配清单。
- 协同技术、商务团队完成信创 GPU 产品的兼容性测试、方案撰写与投标材料筹备，保障项目各环节交付符合招标要求。

解决方案

- 针对邮储银行多业务场景的算力需求，匹配对应规格的国产化 GPU 图形卡，梳理软硬件适配方案，明确与现有信创操作系统、银行业务系统的兼容验证逻辑。
- 配合商务团队完成成本测算、投标应答与方案宣讲，针对性回应招标方关于设备性能、交付周期、售后保障等核心关切，提升方案竞争力。

项目成果

助力团队成功中标邮储银行集采项目，拿下 10 万张 GPU 图形卡订单，加速邮储信创终端国产化替代进程。

2023.02 - 2024.11

紫光计算机-工行/移动集采项目 | FAE 技术支持 |

项目背景

本项目为金融、运营商行业头部客户的商用计算机集采招标项目，需满足客户办公、业务系统对于图形算力适配、稳定运行的要求，为终端产品投标响应、批量交付提供技术支撑。

项目职责

- 协同紫光计算机项目组，负责自研 GPU 图形卡针对工行、移动终端场景的技术支持工作，保障产品符合客户集采技术标准，跟进适配测试、问题排查、方案落地全流程执行。

解决方案

- 梳理工行、移动业务场景的图形算力需求，完成 GPU 驱动、兼容性的针对性适配验证，输出标准化测试报告，配合研发团队定位根因并迭代调整适配方案。

项目成果

支撑 GPU 图形卡成功通过工行、移动集采的技术资质审核，助力终端产品顺利进入集采供应商名录，拿下两个项目预计 30 万张 GPU 图形卡订单。

2024.02 - 2024.10东土科技-机器人项目 | FAE 技术支持 |

项目背景

为布局具身智能赛道，项目联合摩尔线程自研高算力 SOC 芯片、ODM 厂商及工业自动化合作伙伴，共同推进工业机器人的软硬件适配与场景落地。

项目职责

- 协助对接 ODM 厂商与合作伙伴技术团队，梳理 SOC 算力适配需求与机器人场景技术指标，跟进适配过程中的问题同步与协调，参与项目落地全流程对接，负责采购需求梳理、订单跟进与落地交付。

解决方案

- 协同三方团队对齐适配标准，梳理 SOC 算力适配测试关键节点，推动跨方沟通并输出可落地调整方案；梳理采购与交付全流程跟进机制，定期同步订单进度与落地风险。

项目成果

助力完成 SOC 芯片与 1 款工业机器人的适配验证，顺利完成对应采购订单落地执行，推动项目按计划实现场景交付。

2025.12 - 至今雅江集团建研院项目 | 摩尔线程业务和技术对接人 |

项目背景

为响应信创领域国产化自主可控要求，建研院针对建筑设计场景的 3D 建模、性能仿真等高频业务需求，启动图形化工作站全国产化建设项目。

项目职责

- 主导项目整体统筹把控，携手紫光计算机对接各承包商技术团队，拉通需求、方案、测试全链路协作，提供全周期技术支撑，负责国产化图形化工作站方案设计以及测试验证体系搭建与落地标准制定。

解决方案

- 围绕建筑设计业务场景需求，构建适配国产 3D 设计软件、建筑设计专业工具的全国产图形化工作站技术方案，覆盖硬件适配、软件兼容、性能优化全维度要求。

项目成果

支撑项目在多供应商竞争中成功中标，方案获得采购方认可，目前正按计划推进落地部署。

2021.12 - 至今公司大型展会产品支持 | 产品支持 |

项目背景

公司需参与多个行业展会，完成 AI GPU 产品与方案的现场展示，提升品牌影响力与行业认知度。

核心贡献

- 负责年度新品发布会 Demo 部署及讲解，邀请合作商参展。
- 负责 MDC 2025 大型展会医疗板块 Demo 前期厂商对接、环境搭建部署及现场讲解，累计接待专业观众 200+ 人次，获得 10+ 意向合作线索。

- 负责紫光销售大会 AI GPU 服务器 Qwen 大模型展示，完成 OpenClaw + 清华 OpenMAIC 开放式多智能体互动课堂平台 Live Demo 部署与现场讲解。
- 承担 WAIC、中移动装备供应链大会、公司发布会、国内 OS 厂商生态大会、展厅等场景的产品技术讲解工作，累计完成讲解 50+ 场次。

项目成果

所有展会 Demo 零故障运行，累计获得意向合作线索 30+ 条，有效提升了公司产品在 AI 算力领域的品牌知名度。

教育经历

2012.09 - 2015.06

辽宁地质工程职业学院 | 金属矿产地质与勘查技术 | 大专